

Luftqualität in 8 europäischen Hauptstädten

Wie weit über gesunder Luft liegen Europas Städte?

Ein Big-Data-Engineering-Projekt

EEA · Wikipedia · Open-Meteo → Kafka → Spark → Bronze/Silver/Gold

[Name 1] · [Name 2] · [Name 3]

<https://github.com/OnlyMajorG/euro-air-quality-pipeline>

Juni 2026

Der Maßstab: WHO-2021-Richtwerte

Leitfrage

Wie unterscheiden sich PM2.5-, PM10- und NO2-Werte zwischen acht europäischen Hauptstädten – und wie ordnet man sie gesundheitlich ein?

WHO-2021-Jahresrichtwerte (Gesundheits-Orientierung)

PM2.5 = 5 $\mu\text{g}/\text{m}^3$ PM10 = 15 $\mu\text{g}/\text{m}^3$ NO2 = 10 $\mu\text{g}/\text{m}^3$

Datenjahr

Vollständiges Kalenderjahr 2025, gemessene Werte der EEA.

Was in die Analyse einfließt

Umfang

8 Hauptstädte · 365 Tage (2025) · 3 Schadstoffe

Gemessene Datenbasis

2,35 Mio. validierte EEA-Stundenmessungen → 7 938 Tagesmittel (Gold).


Drei Quellarten

EEA-Download (Datei/DB) · Wikipedia (Web-Scraping) · Open-Meteo (REST-API).
Live-Strom über Kafka → Spark: 192 Ereignisse als Echtzeit-Nachweis.

Wissenschaftlicher Grundsatz


Erst Umfang & Abdeckung zeigen, dann interpretieren – Lücken bleiben Lücken.

Alle Städte über den WHO-Richtwerten




- ▶ Jeder NO2-Jahreswert (grün) liegt über der WHO-Linie von 10 µg/m³.
- ▶ PM2.5 (blau) überschreitet bei allen Städten den Richtwert von 5 µg/m³.
- ▶ Rom hat nur validierte NO2-Werte – PM fehlt und wird offen ausgewiesen.

PM2.5: Die östlichen Hauptstädte führen




- ▶ Höchste PM2.5-Mittel: Warschau & Prag ($\approx 14,6 \mu\text{g}/\text{m}^3$).
- ▶ Niedrigste: Madrid, Amsterdam, Wien ($\approx 9\text{--}10 \mu\text{g}/\text{m}^3$).
- ▶ Fehlerbalken = Tag-zu-Tag-Streuung; n = Zahl der Tageswerte.

Verteilungen und Ausreißer




- ▶ Der Median jedes Schadstoffs liegt über dem WHO-Richtwert.
- ▶ Lange Oberschwänze: einzelne stark belastete Tage (Winterspitzen).
- ▶ Mittelwerte allein verbergen diese Streuung – darum Verteilung zeigen.

Saisonalität: der Winter treibt PM2.5




- ▶ Tagesverlauf der datenreichsten Städte – Lücken bleiben sichtbar.
- ▶ Höhere Werte im Winter: Heizung + Inversionswetterlagen.
- ▶ Erklärt, warum einzelne Tage den Jahresmittelwert spürbar heben.

Bevölkerungsdichte erklärt die Belastung nicht



- ▶ Nicht robust: $r = -0,23$ über alle ($n=7$), aber $-0,95$ ohne Paris ($n=6$).
- ▶ Paris = Kernkommune ($\sim 105 \text{ km}^2$) → mit den anderen nicht vergleichbar (MAUP).
- ▶ Bewusst explorativ, kein Signifikanztest – keine Kausalität.

Live-Momentaufnahme (Kafka → Spark)



- ▶ Open-Meteo-Modellwerte, über Kafka produziert und von Spark gelesen.
- ▶ Stundenwerte – bewusst getrennt von den gemessenen EEA-Jahresdaten.
- ▶ Zeigt die Pipeline live, nicht als Ersatz für die historische Analyse.

Was die Daten (nicht) sagen

Deskriptiv, nicht kausal

Wir beschreiben Muster, erklären keine Ursachen.

Keine pauschale Stadt-Rangliste

Die Reihenfolge hängt vom Schadstoff ab – jeder wird einzeln betrachtet.

Ehrlich mit Lücken

Rom ohne validierte PM-Werte: ausgewiesen, nicht aufgefüllt.

Sauber getrennt

Gemessene EEA-Historie vs. Open-Meteo-Live-Modellwerte – nie vermischt.

Kernaussagen

1. Überall zu viel NO₂

Alle acht Städte überschreiten den WHO-NO₂-Richtwert (15–25 statt 10 µg/m³).

2. Schadstoff schlägt Stadt

PM und NO₂ folgen unterschiedlichen Mustern – getrennt betrachten.

3. Kontext erklärt wenig

Bevölkerungsdichte ist kein Erklärungsfaktor für die Belastung.

Repository

<https://github.com/OnlyMajorG/euro-air-quality-pipeline>